

# YOLO 알고리즘을 이용한 전차 국적 식별 및 평가 (Identifications and Evaluation of Tank Nationality using YOLO Algorithm)

임 승 균 <sup>†</sup>  
(Seunggyun Lim)

강 동 수 <sup>††</sup>  
(Dongsu Kang)

**요 약** 인공지능 딥러닝 기술이 적용된 무기체계가 지속적으로 개발된다. 기존의 전차 피아식별 시스템은 사람의 눈으로 표적을 획득하고 공격 여부를 판단한다. 따라서 신속성과 정확성 측면에서 한계가 존재한다. 본 연구에서는 이러한 제한사항을 개선하기 위해 YOLO(You Only Look Once) 알고리즘 기반의 전차 국적 식별 방법을 제안한다. 먼저, 한국, 미국, 일본, 북한의 4개국의 주력 전차 사진을 수집한다. 특히, 실제 기갑 전투의 상황과 유사하도록 노이즈를 추가하고 이미지 전처리 작업을 한다. 이후 데이터셋은 학습 데이터의 적절한 규모를 확인하기 위해 8개의 그룹으로 구성한다. 마지막으로 평가 척도인 mAP와 IoU를 기반으로 적절한 데이터 규모를 분석한다.

**키워드:** 객체탐지, YOLO(You Only Look Once) 알고리즘, 딥러닝, 데이터셋, 전차, 피아식별 시스템, mAP, IoU

**Abstract** Advanced weapon systems with artificial intelligence deep learning technology will be continuously. The existing identification system of friend or foe on tank targets with human eyes determine whether to attack. Therefore, there are limitations in terms of speed and accuracy. In this paper, we propose a YOLO(You Only Look Once) Algorithm-based tank nationality identification method to improve these limitations. First, we collect photos of the main tank from four countries South Korea, the United States, Japan and North Korea. In particular, similar to the actual armored battle, we add noise and do image preprocessing. Afterward, the dataset organized into eight groups to check the appropriate size of the learning data. Finally, we analyze the appropriate data size based on the evaluation scales, mAP and IoU.

**Keywords:** object detection, YOLO(You Only Look Once) algorithm, deep learning, dataset, tank, Identification of Friend or Foe, mAP, IoU

---

<sup>†</sup> 학생회원 : 국방대학교 컴퓨터공학과 학생  
gyun1209@gmail.com  
<sup>††</sup> 종신회원 : 국방대학교 컴퓨터공학과 교수  
(Korea Nat'l Defense Univ.)  
greatkoko@hotmail.com  
(Corresponding author)

논문접수 : 2021년 7월 16일  
(Received 16 July 2021)  
논문수정 : 2021년 10월 18일  
(Revised 18 October 2021)  
심사완료 : 2021년 10월 21일  
(Accepted 21 October 2021)

Copyright©2021 한국정보과학회 : 개인 목적이나 교육 목적인 경우, 이 저작물의 전체 또는 일부에 대한 복사본 혹은 디지털 사본의 제작을 허가합니다. 이 때, 사본은 상업적 수단으로 사용할 수 없으며 첫 페이지에 본 문구와 출처를 반드시 명시해야 합니다. 이 외의 목적으로 복제, 배포, 출판, 전송 등 모든 유형의 사용행위를 하는 경우에 대하여는 사전에 허가를 얻고 비용을 지불해야 합니다.  
정보과학회 컴퓨팅의 실제 논문지 제27권 제12호(2021. 12)

## 1. 서론

전차는 제1차 세계대전 이후 무기체계의 발달과 더불어 끊임없이 발전되어 왔으며, 지상전투의 주력 무기체계이다. 기계화 부대의 전투상황에서 전차포탄은 단 몇 초 만에 적을 제압할 수 있기 때문에 불확실한 전투상황에서 신속하고 정확하게 피아식별하여 적보다 우위를 선점하는 것이 매우 중요하다. 그러나 기존의 피아식별 시스템은 사람에 시각에 의존하는 한계가 존재한다[1].

이러한 한계를 극복하기 위해서 본 연구에서는 객체식별의 대표적인 알고리즘인 YOLO(You Only Look Once)를 이용해 전차를 정확하게 인식하여 국적을 식별하고 평가하는 연구를 진행한다.

먼저 한반도에서 활동 가능성이 높은 한국, 미국, 일본, 북한의 4개국 주력전차 사진을 인터넷에서 각각 500장씩 2,000장을 수집한다. 수집한 데이터는 기계화 부대의 전투상황에서 먼 거리에 있는 상대 전차를 식별하기 제한되는 상황을 고려해 전차의 고속기동으로 인한 흠먼지 노이즈 2,000장과 날씨로 인해 발생할 수 있는 안개 노이즈 2,000장을 이미지 처리하여 데이터 수를 증가시켰다.

다음으로 증가시킨 각각의 데이터에 객체가 어디에 위치해 있는지 학습시키기 위해서 레이블링 툴을 이용해 태그를 붙인다. 이후 YOLOv4 객체식별 알고리즘을 이용하기 위해 실험환경을 구축한다. YOLO 알고리즘은 버전 5까지 나와 있지만, 알고리즘 개발자가 4버전 이후 달라지고, YOLOv5의 경우 공식적으로 논문이 발표되지 않은 상태이기 때문에 본 연구에서는 YOLOv4 알고리즘을 기반으로 다국적 전차를 탐지하고 판별하는 모델을 만들고 테스트 데이터를 통해 모델을 검증한다.

YOLOv4 알고리즘을 이용한 실험은 수집한 데이터를 8개의 그룹으로 구성하고 학습에 앞서 학습 데이터와 검증 데이터의 비율은 8:2의 비율로 나눈다. 실험결과는 mAP(mean Average Precision)와 IoU(Intersection over Union) 척도를 이용하여 평가하고, 실험결과에서 학습 데이터와 검증 데이터를 기준으로 과소 적합(Under Fitting)과 과대 적합(Over Fitting) 여부를 확인해 적절한 데이터셋 규모를 확인한다.

본 연구의 구성은 다음과 같다. 먼저 2장에서는 전차

식별 시스템에 대한 필요성과 객체식별 방법을 살펴본다. 다음으로 3장에서는 전차 국적 식별 방법을 제시하고 4장에서는 실험을 통해 결과를 분석한다. 5장에서는 실험결과를 바탕으로 데이터 규모를 분석하고 마지막으로 6장에서 결론 순으로 마무리한다.

## 2. 관련연구

### 2.1 전차 식별 시스템

기갑 전투에서는 신속성과 정확성이 무엇보다 중요하다. 신속성의 측면에서는 전차포탄의 속도가 1.6km/s 이상이기 때문에 누가 먼저 보고 먼저 쏘느냐에 따라 몇 초 만에 생사가 결정된다. 정확성의 측면에서는 전차포탄의 유효사거리가 다른 지상전투 무기체계에 비해 상대적으로 멀기 때문에 장거리에 있는 전차가 아군전차인지 적군전차인지 정확하게 피아식별 하는 것이 중요하다. 그림 1의 첫 번째 사진과 같이 기존의 피아식별 시스템은 전차 승무원이 전차장 조준경과 포수 조준경으로 전방에 식별되는 전차가 적전차인지 아군전차인지 직접 눈으로 확인하여 시각검색을 하거나 또는 사전에 합의된 동일한 주파수로 교신하여 통신검색으로 피아를 식별한다.

통신검색의 경우에는 주파수가 동일하지 않은 아군전차나 주파수가 같더라도 즉각 교신이 제한되는 경우가 많아 대부분 시각검색을 통해 피아식별 한다. 그러나 시각검색의 경우, 포탑 내부에 있는 조준경 화면을 통해 전차장과 포수의 눈으로 표적을 획득한 후 피아식별을 하고 공격 여부를 판단한다. 즉, 사람의 역량에 따라 피아식별의 신속성과 정확성이 결정된다는 한계가 존재한다.

또한, 신형전차에는 피아식별장치가 있으나 이는 군사용 보조 감시레이더의 일종으로 질문장치와 응답장치로 구성되어 있다. 질문 장치는 정해진 부호전파를 보내고 응답 장치는 수신한 전파를 해독해 별도의 부호전파로 응답을 하게 되는데, 이때 응답이 없거나 틀린 경우 아군이 아닌 것으로 판단하게 된다. 그러나 이 경우에도 판단하는 시간이 소요되고 전파를 받지 못하는 상황에서는 사람의 시각에 의존해 피아식별을 하는 제한사항이 있다.



그림 1 전차 식별 시스템

Fig. 1 Tank Identification System

따라서 그림 1의 마지막 사진과 같이 사람의 능력이 아닌 전차의 감시 장비에서 실시간 자동으로 피아식별을 하게 된다면 지상전투의 주력인 기갑부대의 전투수행능력이 향상될 것이다.

## 2.2 객체식별

객체식별(Object Detection)은 이미지 사진이나 동영상에서 특정 물건, 사람 등 사용자가 지정한 객체를 식별하고 해당 객체의 위치(Bounding Box)를 정확하게 찾기 위한 컴퓨터 시각 기술이다. 분류(Classification)와 위치제안(Regional Proposal)이 모두 수행되어야 하며 기본적인 분류와의 차이점은 그림 2와 같다.

객체식별 알고리즘은 2013년 이후 One-stage detector와 Two-stage detector로 구분되어 발전하였다[2]. Two-stage detector는 위치제안과 분류가 순차적으로 이루어진다[3,4]. 1단계에서 proposal set을 생성한 뒤, 2단계에서는 생성된 proposal set에 대한 특징벡터를 deep CNN(Convolutional Neural Networks)를 이용해 부호화시킨 후 객체에 대한 class를 예측하는 방법이기 때문에 추론 속도가 느리다는 단점이 있다[5].

이러한 단점을 보완하기 위해 등장한 One-stage detector의 대표적인 알고리즘인 YOLO는 다른 모델보다 간단한 처리과정으로 속도를 더 빠르게 하고 이미지 전체를 한 번에 보는 방식이며 객체에 대한 이해도가 높다. 현재는 더 높은 속도와 정확도를 가진 버전 4, 버전 5 등의 향상된 알고리즘이 개발되면서 더욱 활발히 객체식별에 대한 연구가 진행되고 있다[6].

YOLOv1은 2016년에 발표된 최초의 YOLO 논문으로써 26개의 layer를 거쳐 7×7의 grid가 도출되고 각 grid는 bounding box와 신뢰도 점수를 매긴다. 여기서 신뢰도는 객체인지 아닌지에 대한 확률 값과 IoU 값의 곱으로 계산된다[7].

YOLOv2는 YOLOv1보다 속도도 빠르고 학습능력이 더 강력해졌으며[8], YOLOv3는 YOLOv2의 단점이었던 작은 물체나 겹치는 물체를 효과적으로 식별하지 못하는 부분을 보완하였다[9].

YOLOv4는 기존 YOLOv3보다 정확도를 10% 가가



그림 2 분류와 객체식별

Fig. 2 Classification and Object Detection

이 올린 실시간 동작모델이다[10]. Mish 함수[11]를 활성화함수로 사용하였고 BoF(Bag of Freebies), BoS(Bag of Specials), SPP(Spatial Pyramid Pooling), PAN(Path Aggregation Network)을 결합한 결과이다[12].

BoF는 학습하는 과정에서 전략을 수정하거나 학습량을 증가시켜 정확도를 높이고 BoS는 추론 속도의 증가를 통해 정확도를 높이는 방법이다.

기존의 CNN은 고정된 input size를 요구하기 때문에 이미지를 고정된 크기로 맞추기 위해 crop이나 warp과 같은 방법을 사용해 크기를 조절한다.

그림 3은 crop와 wrap의 예시로서 crop는 객체의 전체를 포함하지 못한다는 문제점이 있으며, wrap은 기하학적인 왜곡이 발생 가능하다는 문제점이 있다. 즉, 기존의 CNN 방식의 경우 인위적으로 이미지를 고정된 크기로 변형하면 원본 데이터가 손상되는 문제점이 발생한다.

그러나 SPP의 경우, Input size에 관계없이 이미지 사이즈로부터 자유롭고 이로 인해 객체를 모두 포함하지 못해 생기는 문제점과 기하학적인 왜곡이 생기는 문제점을 해결하여 성능을 개선한다. PAN도 마찬가지로 Layer에서 Feature를 반영하지 못하는 문제를 개선해 성능을 높이는 방법이다.

YOLOv5는 전체적인 모델의 구조는 v4에서 크게 변화가 없으나 Darknet framework가 아닌 PyTorch를 기반으로 하기 때문에 C언어가 아닌 파이썬 언어 기반의 알고리즘이며 변경된 PyTorch의 학습절차로 인해 mAP 향상과 성능을 개선했다.

무기체계를 대상으로 객체탐지 및 분류에 대한 연구는




그림 3 crop와 wrap의 예

Fig. 3 Examples of crop and wrap

표 1 기존 무기체계 객체탐지 및 분류 연구 비교  
Table 1 A comparison of existing weapon system object detection and classification studies

Category	Purpose of study	Algorithm	Data Size
Aircraft	Detecting Aircraft within Satellite Imagery	YOLOv3, Mask R-CNN	1,600
Helicopter	Identification of Friend or Foe	CNN	786
Warship	Detecting Warship Nationality	YOLOv4	10,299
Ship	Detecting Ship in Maritime Image	ResNet	235,002

진행되고 있다. 대표적으로 아래의 표 1과 같이 위성영상 내의 항공기를 식별[13], CNN 기반으로 헬기 기종을 분류하여 피아를 식별[14], 해상 영상에서 군함을 탐지하고 국적을 식별[15], 해상 영상에서 26개 객체의 선박을 분류[16]하는 연구가 있다.

이처럼 항공기와 선박에 대한 연구는 다방면에서 진행되었으나 전차에 대한 연구는 부족하며, 실제 전투상황에 접목시키기 위해 전투상황에서 일어날 수 있는 변수들을 적용하여 효과적으로 식별할 수 있는 연구가 필요하다.

### 3. 전차 국적 식별 방법

그림 4는 전차 국적 식별 방법의 연구절차를 도식화한 것이다. 데이터는 한국, 미국, 일본, 북한의 4개국 주력전차를 수집한다. 사진 처리는 전투상황과 유사하도록 처리하여 사진의 양을 3배로 증가시켰다. 이후 레이블링 툴로 모든 사진 데이터를 레이블링 실시하고 만들어진

데이터셋은 8개의 그룹으로 나누어 YOLOv4 알고리즘으로 학습시킨다. 학습 후에는 학습결과를 분석하고 적절한 데이터 규모를 분석한다.

#### 3.1 데이터 수집 및 사진 처리

사용된 데이터셋은 표 2와 같이 한국, 미국, 일본, 북한의 4개국 전차 사진 자료를 인터넷에서 수집하였으며, 각 나라의 대표 주력전차를 기반으로 대한민국은 K1 전차, K1 전차의 개량 전차(K1E1, K1A1 등), K2 전차를, 미국은 M1A1 전차, M1A2 전차를, 일본은 74식 전차, 90식 전차, 10식 전차를, 북한은 T-55 전차, T-62 전차, M2002 전차, T-72 전차로 구성한다.

일반적으로 컴퓨터 비전 분야의 객체탐지를 연구할 때 충분한 데이터 수집을 위해 이미지의 일부분을 자르거나 회전하여 부족한 데이터를 보충하는 방법을 적용한다.

그러나 단순 회전을 통한 데이터 증가는 Darknet에서 설정을 통해 회전시켜 학습시킬 수 있으며 노이즈가 없는 깨끗한 원본 사진만을 학습할 경우, 선명한 객체만 식별하고 노이즈가 많은 객체는 식별하지 못할 수 있기 때문에 전투상황에서 일어날 수 있는 노이즈를 고려하여 사진 처리를 함으로써 데이터를 증가시킨다.

본 연구에서는 실제 전투상황과 유사하도록 전차 이

표 2 전차 사진 데이터 수  
Table 2 Number of Tank Image Data

Category	KOR	US	JAP	NK
Sum	1,500	1,500	1,500	1,500
Original Image	500	500	500	500
Dust Processing	500	500	500	500
Fog Processing	500	500	500	500

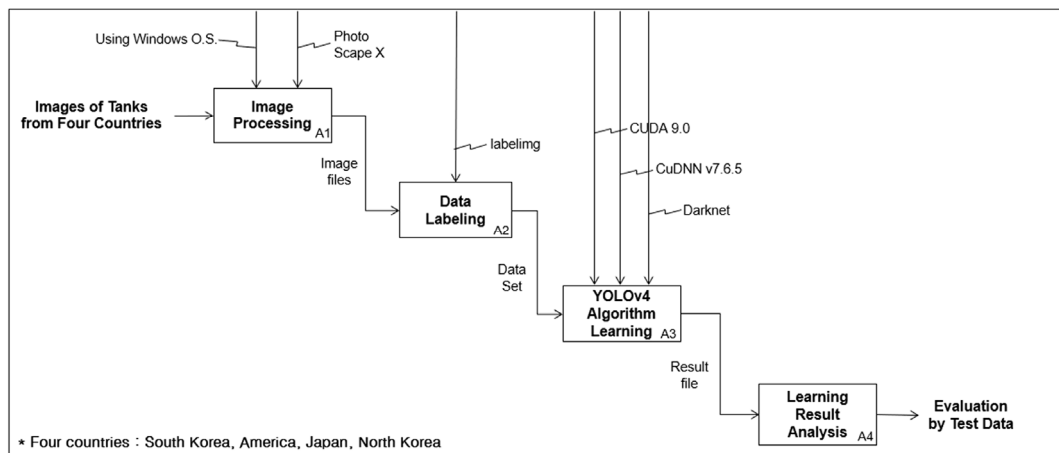


그림 4 연구 프로세스

Fig. 4 The research process

표 3 전차 사진 처리

Table 3 Tanks Image Processing



미지에 흙먼지와 안개 처리를 통해 이미지의 양을 3배로 증가시켰다. 실제 기계화 부대의 경우 전차 기동으로 인해 흙먼지가 많을 수 있는 상황이 발생할 수 있고 날이 흐리거나 안개로 인해 식별이 제한되는 상황을 고려하여 표 3과 같이 전차 사진을 처리한다.

각 나라별 원본 사진은 500장씩 수집하였으며 흙먼지 처리와 안개 처리를 하여 한국, 미국, 일본, 북한 각 국가별 1,500장씩 총 6,000장으로 데이터를 구성한다.

### 3.2 데이터 레이블링

수집과 전처리된 6,000장의 전차 사진을 그림 5와 같이 labeling 프로그램을 사용하여 레이블링 작업을 한다.

레이블링을 하고 나면 아래의 그림 6과 같이 메모 파일이 생성되는데, 가장 앞의 숫자는 class를 뜻하게 되며 나머지 4개 그룹의 숫자는 해당 이미지에서 박스의 좌표를 의미한다.



그림 5 전차 사진 레이블링

Fig. 5 Labeling of Tank Images




그림 6 레이블링 파일

Fig. 6 Labeling of Files

### 3.3 데이터셋 구성

데이터셋 구성은 표 4와 같이 실험 데이터와 검증 데이터를 8:2의 비율로 구성한다. 제한적이지만 수집된 데이터 규모에서 적절한 학습 데이터 규모를 분석하기 위해 8개의 그룹으로 나누어 실험한다.

표 4 데이터셋 구성

Table 4 Configuration of Dataset

Category		KOR	US	JAP	NK
Set1	Sum	190	190	190	190
	Test Set	150	150	150	150
	Validation Set	40	40	40	40
Set2	Sum	375	375	375	375
	Test Set	300	300	300	300
	Validation Set	75	75	75	75
Set3	Sum	560	560	560	560
	Test Set	450	450	450	450
	Validation Set	110	110	110	110
Set4	Sum	750	750	750	750
	Test Set	600	600	600	600
	Validation Set	150	150	150	150
Set5	Sum	750	750	750	750
	Test Set	750	750	750	750
	Validation Set	190	190	190	190
Set6	Sum	1,125	1,125	1,125	1,125
	Test Set	900	900	900	900
	Validation Set	225	225	225	225
Set7	Sum	1,310	1,310	1,310	1,310
	Test Set	1,050	1,050	1,050	1,050
	Validation Set	260	260	260	260
Set8	Sum	1,500	1,500	1,500	1,500
	Test Set	1,200	1,200	1,200	1,200
	Validation Set	300	300	300	300

## 4. 실험 및 평가

### 4.1 실험 환경과 평가 척도

딥러닝 YOLOv4 모델을 활용하여 다국적 전차 식별 실험을 위해 구성한 환경은 아래 표 5와 같으며 CUDA 9.0, CuDNN v7.6.5 for CUDA 9.0를 이용해 실험하고 프로그램은 Darknet을 이용한다.



표 5 실험을 위해 구성한 환경

Table 5 Environments Configured for Experiments

Device	Specification
Processor	Intel(R) Core(TM) i5-10400 2.90GHz
RAM	16GB
GPU	NVIDIA GEFORCE GTX 1070Ti



그림 7 IoU 측정방법

Fig. 7 Measurement Method of IoU

일반적으로 객체식별 연구에서 성능을 확인하는 지표는 Bounding Box를 얼마나 잘 찾아내는지에 대한 식별률 척도를 나타내는 IoU와 mAP를 도출하여 모델의 정확도를 평가한다.

먼저 식별률을 나타내는 IoU는 실제 정답(Ground truth)과 모델이 예측한 결과(Prediction)가 얼마나 정확하게 겹치는지를 전체 합집합의 면적으로 교집합의 면적을 나누어 측정하게 된다. 즉, 그림 7과 같이 모델이 실제 정답과 유사하도록 Bounding Box를 예측했는지와 더불어 Bounding box 안에 원하는 객체의 Class 구분을 잘 했는지를 측정한다.

또한, 객체를 정확하게 예측했는지를 확인하기 위해서 TP(True Positive), FP(False Positive), FN(False Negative), TN(True Negative)을 통해 Precision과 Recall, mAP를 측정하여 평가한다.

Precision은 모델이 예측한 결과의 Positive 결과가 얼마나 정확한지를 나타내고, Recall은 검출해야 하는 객체들 중에서 정확하게 검출된 객체의 비율은 어느 정도 인지를 의미하며 수학적 정의는 아래와 같다.

$$Precision = \frac{TP}{TP+FP}$$

$$Recall = \frac{TP}{TP+FN}$$

mAP(mean Average Precision) 값은 Precision과 Recall을 이용하여 학습하는 동안 검출하는 결과를 바탕으로 PR 곡선(Precision-Recall 그래프)을 그리고 선 아래쪽의 면적을 단조적으로 변경한 후 넓이를 구해 계산한다. 이는 객체식별 연구에서 알고리즘의 정확도 성능을 평가하는 중요한 지표이다.

## 4.2 YOLO를 이용한 학습

YOLOv4를 이용하여 학습시킬 때에는 학습효과를 높이기 위해 Darknet에서  $-10^{\circ} \sim +10^{\circ}$ 까지 회전시킴으로써 데이터를 추가로 증강시켜 학습을 진행한다. Input size는  $416 \times 416$ , Iteration은 일반적으로 YOLOv4를 사용 시 적용하는 Class의 수  $\times 4,000$ 을 적용하여 16,000회, Learning rate는 GPU 환경을 고려하여 0.0013으로 설정한다.

그림 8은 식별률이 가장 높았던 Set 5를 알고리즘에 학습시켰을 때, 학습이 진행되면서 mAP 값과 Loss 값이 변화되는 과정을 그린 그래프이다. 학습이 진행되는 과정에서 mAP(빨간색 실선)는 높아지고 Loss(파란색 실선)는 낮아지며 학습이 잘 진행되었음을 확인할 수 있다.

표 6은 국가별 평가 결과이며 AP 값은 모두 95%이상으로 높게 나타난다. 세부적으로 Japan이 99.75%로 가장 높고 South Korea가 97.71%로 가장 낮다.

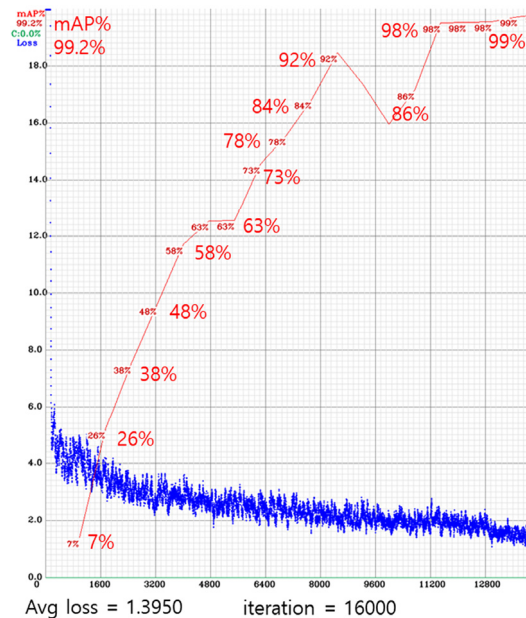


그림 8 mAP와 Loss 그래프

Fig. 8 mAP and Loss Graph

표 6 평가 결과

Table 6 Evaluation Results

Class	AP	TP	FP
South Korea	97.71%	185	7
America	99.72%	188	13
Japan	99.75%	190	4
North Korea	99.57%	184	6

#### 4.3 테스트 데이터에 의한 평가

테스트 데이터는 한국, 미국, 일본, 북한의 주력전차를 위주로 영상을 제작하였으며, 실제 전투상황에서도 판별이 가능한지 확인하기 위하여 고속기동 영상, 기동으로 인한 흠먼지가 많은 환경에서의 영상, 날씨로 인해 안개가 많이 있는 영상을 포함하여 데이터를 편집하였다. 테스트 데이터를 평가하는 방법은 식별하고자 하는 전차를 정확한 위치에 Bounding Box를 통해 분류하는지 확인하며, 그 결과는 아래 그림 9와 같다.

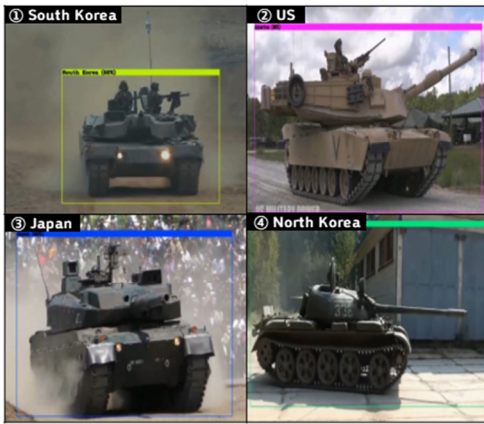


그림 9 국적 식별 결과

Fig. 9 Results of Nationality Identification

#### 5. 학습결과 및 데이터 규모 분석

일반적으로 객체식별 연구에서는 데이터의 수집과 레이블링, 학습시간에서 가장 많은 시간과 노력이 소모되기 때문에 적절한 데이터 규모를 찾는 것이 중요하며 본 연구에서 데이터셋 별로 학습하여 평가척도를 확인한 결과는 표 7과 같다.

정확도를 나타내는 평가척도인 mAP은 모든 데이터셋이 98% 이상으로 크게 차이가 없었으나, 평균 식별률을 나타내는 Average IoU의 경우 Set 5를 기준으로 적은 양의 데이터로 학습한 경우에 비해 데이터양이 많아질수록 점차 평균 식별률이 높아지는 것을 확인할 수 있었다. 또한 그보다 더 많은 양의 데이터로 학습할 경우에는 Set 5에 비해 평균 식별률이 더 낮아지거나 큰 차이가 없는 것으로 나타났다.

이는 Set5의 데이터셋 보다 더 많은 양의 데이터를 수집하는 경우에는 불필요한 시간과 노력이 소모되고 더 적은 양의 데이터를 수집하는 경우에는 모델의 효율성이 떨어지기 때문에 적절한 데이터 규모를 가진 데이터셋은 Set 5임을 알 수 있다.

Set 5는 학습 데이터 원본, 흠먼지 처리, 안개 처리한

표 7 평가 결과

Table 7 Evaluation Results

Set	mAP	Average IoU	Precision	Recall
Set 1	98.25%	78.71%	0.90	0.94
Set 2	98.35%	82.06%	0.94	0.96
Set 3	98.32%	82.25%	0.94	0.96
Set 4	99.52%	83.68%	0.96	0.98
Set 5	99.18%	83.87%	0.96	0.98
Set 6	99.05%	81.95%	0.95	0.98
Set 7	99.08%	83.64%	0.96	0.98
Set 8	98.31%	82.39%	0.95	0.96




그림 10 mAP와 Average IoU 비교

Fig. 10 Comparison Between mAP and Average IoU

사진을 각각 250장씩 총 750장으로 학습시켰으며 검증 데이터는 190장으로 실험한 데이터셋이다.

그림 10은 데이터셋 별로 mAP와 Average IoU를 한 눈에 볼 수 있도록 그래프로 나타낸 것으로 Set5를 기준으로 더 적은 양의 데이터로 학습할 경우에는 과소적합의 경향이 나타나 평균 식별률이 낮아지는 것을 확인할 수 있었고 더 많은 양의 데이터로 학습할 경우에는 과대적합의 경향이 나타나 Set5에 비해 평균 식별률이 낮은 것을 확인할 수 있다.

#### 6. 결론 및 향후 연구

본 연구는 육군의 주력인 전차에 대해 딥러닝의 객체 탐지에 기초하여 다국적 전차를 식별하고 국적까지 분류하는 모델을 만들고 검증하였다. 특히, 기갑 전투의 특성을 활용하여 고속기동에 따른 흠먼지가 일어날 수 있는 상황과 날씨로 인해 안개가 발생할 수 있는 상황을 고려하여 이미지를 처리하였으며 데이터셋은 총 8개 그룹으로 나누어 실험하였고 가장 적절한 데이터 규모를 분석하였다.

딥러닝을 무기체계에 접목시켜 효과적으로 활용되기 위해서는 충분한 데이터가 확보되고 여러 무기체계의 데이터를 구축해야 한다. 향후 야간 전투상황을 고려하여 전차의 적외선 이미지 데이터를 확보하고 DB화하여 객체식별 연구를 진행할 예정이다.

## References

- [1] S. Lim and D. Kang, "A Method of Identify Nationality of Tank using YOLO Algorithm," *Proc of the Korea Computer Congress 2021*, pp. 52-54, Jun. 2021. (in Korean)
- [2] X. Youzi, T. Zhiqiang, Y. Jiachen, and Z. Yinshu, "A Review of Object Detection based on Deep learning," *Journal of Multimedia Tools and Applications*, Vol. 79, No. 33-34, pp. 23729-23791, Sep. 2020.
- [3] R. Girshick, "Fast r-cnn" *Proc of the IEEE International Conference on Computer Vision*, pp. 1440-1448, Sep. 2015.
- [4] S. Ren, K. He, R. Girshick, and J. Sun, "Faster r-cnn: Towards real-time object detection with region proposal networks," *Journal of IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol. 39, No. 6, pp. 1137-1149, Jun. 2017.
- [5] R. Girshick, J. Donahue, T. Darrell, and J. Malik, "Rich feature hierarchies for accurate object detection and semantic segmentation," *Proc of the IEEE Conference on Computer Vision and Pattern Recognition*, pp. 580-587, Jun. 2014.
- [6] P. Alexander, H. Jan, and C. Jorge, "A baseline for General Music Object Detection with Deep Learning," *Journal of MDPI*, Vol. 8, No. 9, pp. 1488-1508, Aug. 2018.
- [7] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," *Proc of the IEEE conference on computer vision and pattern recognition*, pp. 779-788, Jun. 2016.
- [8] J. Redmon and A. Farhadi, "YOLO9000: Better, Faster, Stronger," *Proc of the IEEE/CVF International Conference on Computer Vision*, pp. 6517-6525, Dec. 2017.
- [9] J. Choi, D. Chun, H. Kim, and H. Lee, "Gaussian YOLOv3 : An accurate and Fast Object Detector Using Localization Uncertainty for Autonomous Driving," *Proc of the IEEE/CVF International Conference on Computer Vision*, pp. 502-511, Sep. 2019.
- [10] A. Bochkovskiy, C. Wang, and H. Liao, "YOLOv4: Optimal Speed and Accuracy of Object Detection," *arXiv preprint arXiv:2004.10934*, Apr. 2020.
- [11] D. Misra, "Mish: A self regularized non-monotonic neural activation function," *arXiv preprint arXiv:1908.08681*, Aug. 2019.
- [12] C. Wang, H. Liao, Y. Wu, P. Chen, J. Hsieh, and I. Yeh, "CSPNet: A new backbone that can enhance learning capability of cnn," *Proc of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 390-391, Nov. 2019.
- [13] J. Jang and S. Lee, "A coupled CNN Algorithm for the Reduction of False Positive Rate in Detecting Aircraft within Satellite Imagery," *Journal of Military Art and Science*, Vol. 76, No. 3, pp. 61-90, Oct. 2020. (in Korean)
- [14] T. Kim, J. Kim, and H. Moon, "The Study on The Identification Model of Friend or Foe on Helicopter by using Binary Classification with CNN," *Journal of the Korea Society of Computer and Information*, Vol. 25, No. 3, pp. 33-42, Mar. 2020. (in Korean)
- [15] J. Kim, J. Park, and H. Moon, "The study on the multinational warship detection and classification model using deep learning in maritime image information," *Journal of the Military Operations Research Society of Korea*, Vol. 46, No. 2, pp. 73-83, Dec. 2020. (in Korean)
- [16] H. Shin and K. Lee, "Classification Maritime Vessel Image utilizing a Region of Interest Extracted and Convolution Neural Network," *Journal of Korean Institute of Intelligent System*, Vol. 29, No. 4, pp. 321-326, Aug. 2019. (in Korean)



임 승 균

2015년 단국대학교 스포츠경영학(학사)  
2020년~현재 국방대학교 컴퓨터공학 전공 석사과정. 관심분야는 인공지능, 딥러닝, YOLO(You Only Look Once), 객체식별

강 동 수

정보과학회 컴퓨팅의 실제 논문지  
제 27 권 제 1 호 참조