

데이터증강 모델 조합을 활용한 적성 전차에 대한 객체탐지 성능 향상 연구

황교성 · 마정목[†]

국방대학교 국방과학학과

Improvement of Object Detection Performance for Enemy Tanks Using the Combination of Data Augmentation Models

Kyoseong Hwang and Jungmok Ma[†]

Dept. of Defense Science, Korea Nat'l Defense Univ.

Received 23 February 2022; received in revised form 5 May 2022; accepted 6 May 2022

ABSTRACT

With the development of artificial intelligence technology, it is continuously being applied in the defense field. In particular, deep learning-based object detection technology is treated as a groundbreaking technology in the field of defense surveillance and reconnaissance. However, there are limitations to use deep learning-based object detection technology because it is hard to get enough image data of enemy weapon systems. To overcome this challenge, this paper studies the improvement of object detection performance for enemy tanks using the combination of data augmentation models. Experiment results show that the combination of selected data augmentation models improves object detection performance(especially SinGAN model is effective). The result indicates that the data augmentation in the field of defense surveillance and reconnaissance needs to be studied since the result of combining all data augmentation models would not necessarily be good.

Key Words: Data Augmentation, Object Detection, Mosaic Augmentation, SinGAN, RandAugment YOLOv5

1. 서 론

4차 산업혁명 시대에 들어서면서 인공지능 기술은 다양한 산업분야에서 적용 및 연구되고 있다. 국방분야에서도 2019년 12월에 발표된 인공지능 국가전략에 따라 인공지능 발전계획을 수립하고 관련 부서를 설립하면서 인공지능 역량 강화를 위

해 노력하고 있다^[1]. 국방분야에서 인공지능 활용이 유망한 분야는 현재와 미래의 데이터 확보가 상대적으로 용이하고 민간분야의 인공지능 기술과 스핀 온, 오프가 용이한 감시정찰 분야로 평가된다^[2]. 감시정찰 분야에서 높은 활용성이 기대되어 많은 연구가 이뤄지고 있는 인공지능 기술은 주어진 이미지 또는 동영상에서 의미 있는 객체의 종류와 그 위치를 찾는 객체탐지(Object detection) 기술이다.

객체탐지라는 인공지능 기술은 최근 딥러닝 기

[†]Corresponding Author, jxm1023@gmail.com
©2022 Society for Computational Design and Engineering

반의 모델을 활용하는 방향으로 연구되고 있다. 딥러닝 기반의 객체탐지 모델들은 다층으로 구성된 인공기능 신경망을 통해 주어진 데이터의 특징을 파악한다. 특징을 파악하는 과정에서는 모델이 데이터에 편향되는 과적합(Overfitting)을 방지하기 위해 객체탐지 모델의 학습시 빅데이터(Big data)가 필수적이다^[3].

하지만, 객체탐지 관련 무기체계를 설계하는데 있어 아군이 아닌 적군의 데이터를 수집하여 빅데이터를 구축하는 것은 제한사항이 있다. 특히, 다른 국가보다 폐쇄적인 북한의 무기체계 데이터를 확보하는 것은 어려움이 따른다. 적군 무기체계와 같은 종류의 아군 무기체계 데이터를 구축하는 방법으로 일부 해결이 가능하지만 적군 무기체계 데이터를 구축하는 방법보다 객체탐지 정확도가 떨어지고 피아가 혼재된 전장에서 형태가 유사한 아군과 적군의 전차를 구분하기 위해서는 적성 무기체계 데이터의 확보 및 적합한 구성은 중요하다.

적성 무기체계의 데이터베이스 구축이라는 특수한 국방분야의 상황을 해결하기 위한 방법으로 제한된 데이터를 증강시켜 학습 데이터의 수를 추가적으로 확보하는 데이터증강(Data augmentation)에 대한 연구가 이루어지고 있다. 데이터증강에 관한 기존 연구들은 PASCAL VOC(Pattern Analysis, Statistical Modeling and Computational Learning Visual Object Classes), MS COCO(Microsoft Common Objects in Context)와 같은 데이터셋에 대한 단일 데이터증강 모델 적용 이후 객체탐지 성능 평가를 진행하였다. 하지만, PASCAL VOC, MS COCO와 같이 일상생활에 흔히 볼 수 있는 객체로 구성된 데이터셋은 적성 무기체계를 탐지해야 하는 국방분야의 특수한 상황에서 사용하기가 어렵다^[4]. 따라서 국방분야에 적합한 데이터 구성 및 데이터증강에 관한 연구가 필요하다.

본 연구에서는 적성 무기체계 중 적성 전차 객체탐지를 위한 데이터셋을 구성하고 적합한 데이터증강 모델들을 선정한다. 선정한 모델들은 서로 간의 조합을 통해 객체탐지 성능 향상에 관한 연구를 진행한다. 본 연구는 적성 무기체계 데이터에 데이터증강 조합 모델을 적용한 최초의 연구로서 객체탐지 관련 무기체계에 적용 및 데이터베이스 구성에 참고가 가능한 연구이다.

본 연구는 2장에서 연구에 사용된 데이터증강

모델 및 객체탐지 모델에 대한 관련 연구를 알아본다. 3장은 실험 데이터셋의 구성과 데이터증강 모델에 따른 데이터셋의 변화를 제시한다. 4장에서는 데이터증강 모델의 조합별 객체탐지 성능을 평가하고 5장에서는 연구의 결론 및 제한사항을 도출한다.

2. 관련 연구

2.1 이미지 데이터증강

이미지 데이터증강은 객체탐지 모델의 학습 이미지 데이터 수량을 늘리기 위해 연구되는 분야로서 추가적인 데이터를 확보하는 것과 달리 기존의 데이터를 활용하여 데이터의 수를 증가시키는 방법이다. Fig. 1과 같이 이미지 데이터증강은 Basic image manipulation, Deep learning approaches, Meta learning이라는 3가지 분류로 나뉘어진다. Basic image manipulation은 가장 기본적인 데이터증강 모델들로 기존의 이미지를 회전, 색상변경, 합치기, 일부 삭제 등 이미지의 기하학적 특성을 변형시킨 데이터를 증강 데이터로 사용한다. Deep learning manipulation은 데이터증강에 GAN(Generative Adversarial Network)과 같은 딥러닝 모델을 활용하여 데이터를 증강한다. Meta learning은 데이터증강에 사용되는 최적의 하이퍼파라미터를 학습의 과정을 통해 도출하고 도출한 방법들을 활용하여 데이터증강을 하는 방법이다. 본 연구에서 활용하는 데이터증강 모델은 데이터증강 모델을 구성하는 3가지의 대분류내에서 대표적인 모델들을 선정하였다.

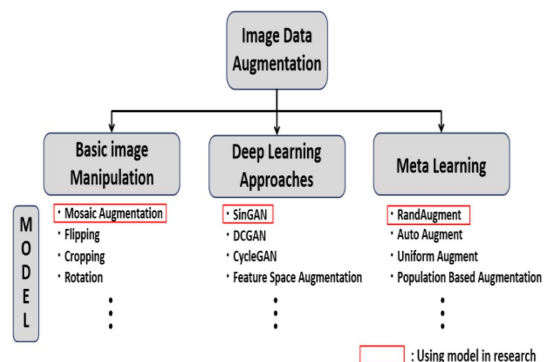


Fig. 1 Classification of image data augmentation (Revised from^[5])

2.1.1 Mosaic Augmentation

본 연구에서 사용된 Mosaic Augmentation^[6] 모델은 기존 네 개의 원본 이미지의 잘라낸 부분들을 조합하여 새로운 이미지를 형성한다. 각 이미지의 일부를 잘라낼 때에는 객체탐지에 사용될 수 있도록 바운딩 박스가 포함된 부분을 잘라낸다. 기존 이미지의 어느 부분을 잘라내고 새로운 이미지 형성이 기존 이미지를 조합하는 방법에 따라 다양한 이미지를 형성한다. 이 과정에서 이미지의 batch 사이즈를 키워 객체탐지 모델의 학습효과를 증대 시키므로 객체탐지 데이터셋에 대한 데이터증강 모델로 자주 사용된다.

Wei *et al.*^[7]은 항공사진 속 작은 물체들에 대한 객체탐지 성능이 Mosaic Augmentation을 통한 데이터증강을 통해 향상됨을 보였다. Hao *et al.*^[8]은 Mosaic Augmentation이 복잡한 배경에서 객체탐지 성능이 우수하고 GPU(Graphics Processing Unit) 컴퓨팅 메모리를 적게 소모하여 범용성이 높은 데이터증강 방법임을 증명하였다.

2.1.2 SinGAN

본 연구에서 사용된 SinGAN(Single Generative Adversarial Network)^[9] 모델은 많은 학습 이미지에 대해 생성기와 판별기 네트워크의 대립구조를 통해 이미지를 증강하는 기존의 GAN 모델과는 달리 단일 이미지를 통해 이미지를 증강한다. 단일 이미지만으로도 기존과 유사한 이미지를 형성할 수 있다는 특징으로 인해 소규모 데이터셋에 대한 데이터증강 모델로 주로 사용된다.

Kwon *et al.*^[10]은 SinGAN 모델을 통해 수가 적은 병리 데이터의 증강방법이 데이터 분류 학습

성능을 향상시킨다는 것을 보였다. Chen *et al.*^[11]은 이하의 공동을 탐지하는 지표투과레이더 데이터를 SinGAN 모델을 통해 증강하였을 때, 객체탐지 성능이 향상됨을 보였다.

2.1.3 RandAugment

본 연구에서 사용된 RandAugment^[12] 모델은 딥러닝 모델의 정책에 따른 최적의 데이터증강 방법을 찾기 위한 시도에서 시간과 비용이라는 현실적인 문제를 해결하고자 제시된 방법이다. RandAugment 모델은 Fig. 2와 같이 기존 이미지를 기하학적으로 변형시킬 방법과 그 강도를 설정하여 이미지를 증강하는 방법이다. 변형 방법은 14가지의 방법 중 몇 가지의 방법을 적용할지 설정하면 무작위로 설정되고 강도는 0~30범위에서 설정한다. RandAugment 모델은 Fig. 1의 Meta Learning 모델 중 비교적 적은 컴퓨팅 시간에 높은 성능 달성이 가능하여 각종 딥러닝 모델 관련 분석 대회에서 주로 사용된다.

Yao *et al.*^[13]은 불균형하고 양이 적은 데이터셋을 바탕으로 피부 병변 이미지를 분류하는 과정에서 RandAugment를 활용한 데이터증강 방법이 이미지 분류 성능을 향상시킬 수 있음을 보였다. 또한, Lee *et al.*^[14]은 농작물에 대한 객체탐지 과정에서 RandAugment를 활용하여 이미지를 증강하였을 때, 객체탐지 성능이 향상됨을 보였다.

2.2 무기체계 객체탐지

무기체계 객체탐지에 관련된 기존 연구는 Table 1과 같다. 각종 연구에서 탐지하고자 하는 무기체계는 전차, 잠수함, 군함, 항공기와 같이 다양한 전

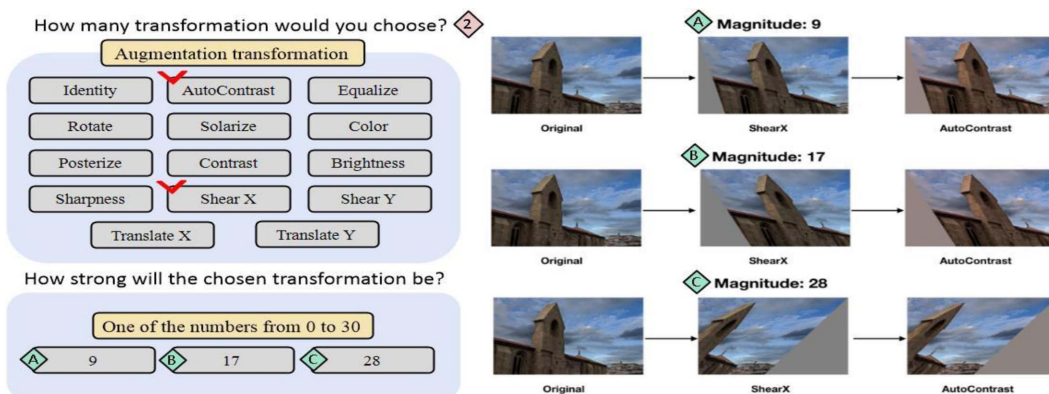


Fig. 2 Examples of RandAugment (Revised from^[12])

장에서 운용되는 체계이다. 주로 사용된 객체탐지 모델은 다른 객체탐지 모델에 비해 처리속도가 빠르면서 정확도도 높은 YOLO(You Only Look Once) 모델이다.

Table 1 Existing weapon system object detection studies

Researcher	Target	Object Detection Model
Lim <i>et al.</i> ^[15]	Tank	YOLOv4
Kim <i>et al.</i> ^[16]	Submarine	SSD
Kim <i>et al.</i> ^[17]	Warship	YOLOv4
Jang <i>et al.</i> ^[18]	Aircraft	YOLOv3

본 연구는 데이터증강 모델의 조합을 통해 구성된 데이터셋에 대해 최종적으로 YOLOv5^[19] 객체 탐지 모델을 사용하여 성능을 평가한다. YOLOv5 모델은 파이토치를 프레임워크로 사용하며 모델을 구성하는 네트워크는 Fig. 3과 같이 Backbone, Neck, Output 세 가지 주요 부분으로 구성된다. Backbone에서는 입력된 이미지의 특징 정보를 추출하고 Neck에서는 추출된 세가지 특징 맵의 세 가지 그리드를 생성한 뒤 Output에서 생성된 특징 맵을 활용하여 객체를 탐지한다. YOLOv5 모델의 Anchor box는 각 특징맵별 3개의 Anchor box를

사용하여 총 9개의 Anchor box로 구성된다.

본 연구는 객체탐지 모델을 드론이나 소형 UAV와 같은 소형 감시정찰 무기체계에 적용하기에 보다 용이하다고 판단되는 YOLOv5 모델 중 YOLOv5s 모델을 사용한다. 해당 모델은 모델 내부 파라미터 수(12.7M)가 적어 경량화된 모델로서 탐지 시간(19~21 ms)이 빠르고 탐지 성능이 우수하다. 또한, 적성 전차 객체탐지를 위해 구성된 데이터 수의 부족함으로 인한 과적합을 방지하기 위하여 MS COCO 데이터셋으로 사전 학습된 모델을 사용한다. 특히, 본 연구는 기존연구와는 다르게 데이터증강 모델의 조합이 객체탐지 성능 향상에 미치는 영향에 중점을 두고 실험을 진행한다.

3. 데이터 구성

3.1 실험 데이터셋

실험에 사용할 적성 무기체계는 북한군 전차이다. 북한군 전차는 대다수 1세대 전차인 T-54, T-55 전차로 이루어져 있었으나 현재는 T-62 전차를 기반으로 개량한 2세대 전차인 천마호와 폭풍호로 전력을 교체 중이고 T-72 전차를 기반으로 개량한 2.5세대 전차인 선군호를 보유하고 있다^[21]. 2020년 10월 10일 조선노동당 창건 75주년 열병

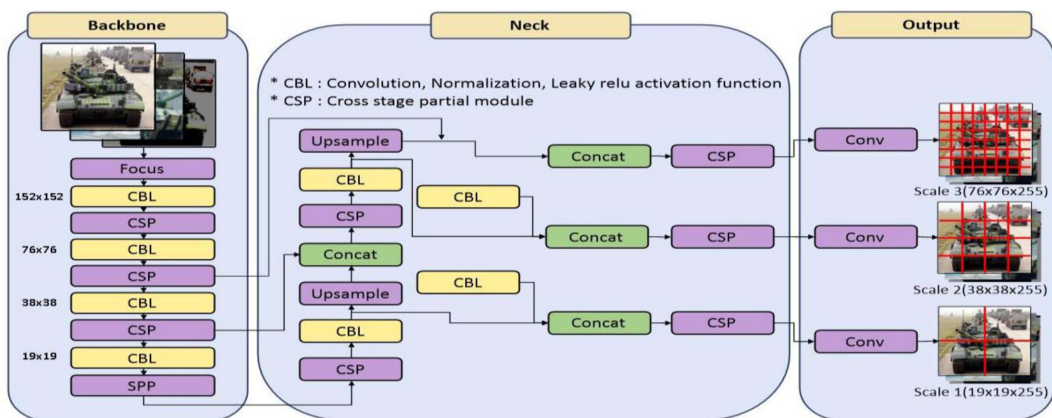


Fig. 3 Architectures of YOLOv5s (Revised from^[20])

Table 2 Military Tank Dataset

Name	T-72	T-80	T-90	Type 96	Type 99	PokPoong	Seongun	M-2020
Training set (Basis)	4	5	5	4	5	4	5	4
Test set	9	8	8	9	8	9	8	1
Total	96							

식에는 최초로 선보인 최신전차인 M-2020(가칭)이 등장하였다. 해당 전차에 대한 정보는 적성 무기체계의 특징상 많은 자료는 없지만 기존 전차와 같이 T계열 전차를 개량했을 것으로 추측하고 있다.

북한군 전차 이미지는 열병식에서 공개된 이미지가 대다수이므로 다양한 형태의 이미지를 확보하기 위해 북한군 전차의 모체인 러시아의 T계열 전차와 북한군 전차와 형상이 유사한 중국의 Type 99 전차들의 이미지를 Kaggle에 공개된 Military Tank Dataset^[22]과 Google 이미지를 활용하여 Table 2와 같이 데이터셋을 구성하였다. 또한, 데이터의 편중을 완화하기 위해 Fig. 4와 같이 전차의 전·측·후면, 이미지 내 전차 대수의 변화, 기동 및 사격하는 전차 등 다양한 상황 속의 전차 이미지를 포함하였다.



Fig. 4 Various aspect of Tank Dataset

3.2 실험 데이터증강

데이터증강 방법은 2장 1절에서 제시한 3가지 방법을 사용하였다. Fig. 5의 Mosaic Augmentation을 통한 전차 이미지의 증강은 다양한 전차 이미지가 2 × 2 Grid에 조합된 모습으로 기존 이미지 그대로를 조합하지 않고 기존 이미지 중 바운딩 박스에 포함된 이미지의 일부를 잘라내어 증강 이미지에 조합한다. Fig. 6의 SinGAN을 통한 전차 이미지의 증강은 Fig. 4의 기존 이미지와 비교했

을 때, 전차의 큰 형상은 유지하나 전차의 반응장갑, 광학장비, 포신, 궤도 등 일부분에 노이즈가 추가된 증강 이미지가 형성된다. Fig. 7의 RandAugment를 통한 전차 이미지의 증강은 Fig. 4의 기존 이미지와 비교했을 때, 단일 이미지의 음영, 회전, 잡음 등이 반영되어 학습 데이터로 사용된다.



Fig. 5 Using Mosaic Augmentation for Tank Dataset



Fig. 6 Using SinGAN for Tank Dataset



Fig. 7 Using RandAugment for Tank Dataset

3.3 데이터 라벨링

객체탐지 모델에 전차 이미지를 학습시키고 성능을 평가하기 위해 기존 이미지 및 3가지 방법

으로 증강한 이미지에 바운딩 박스를 표시하는 라벨링 과정을 거친다. 각 이미지에 대한 라벨링은 Fig. 8과 같이 Roboflow를 활용하여 실시하고 이미지의 크기는 256×256 pixel 사이즈로 설정한다.



Fig. 8 Data labeling by using Roboflow

4. 객체탐지 실험

4.1 실험 목적

실험의 목적은 적성 전차 이미지 데이터를 단일 데이터증강 모델 또는 데이터증강 모델들의 조합을 활용하여 증강된 데이터셋을 구성하였을 때, 구성된 데이터셋에 대한 객체탐지 모델의 성능 향상이 어떠한지 알아보는 것이다. 이를 위해 3장에서 구성한 적성 전차 데이터셋에 대해 2장 1절에서

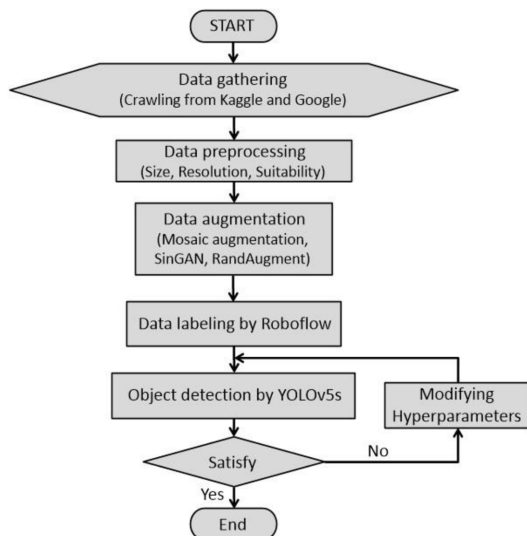


Fig. 9 Research flow chart

제시한 3가지 데이터증강 모델들을 활용하여 증강된 데이터셋을 구성하고 2장 2절에서 제시한 YOLOv5s 객체탐지 모델을 활용하여 객체탐지 성능 향상에 대해 분석한다. 실험 과정을 순서도로 나타내면 Fig. 9와 같다.

4.2 실험 환경

실험은 Google Colaboratory를 활용하여 진행하였다. 개별 데이터증강 모델 및 객체탐지 모델의 구동 환경은 Table 3과 같다.

Table 3 Model Environment

SPEC	Mosaic Augmentation	Rand Augment	Sin GAN	YOLO v5s
CPU/ GPU	Intel(R) Xeon(R) CPU @ 2.30 GHz		Tesla P100	
RAM	25.51GB			
GP GPU	-		CUDA 11.1	
Python	3.7.12			
Frame work	Pytorch 1.7.0	Tensor flow 2.7	Pytorch 1.4.0	Pytorch 1.7.0

4.3 실험 구성

실험에 사용되는 Table 2 Military Tank Dataset을 YOLOv5s 모델에 적용한다. Table 4는 실험별 훈련 데이터 셋과 테스트 데이터 셋의 구성을 나타낸다. 기존 이미지와 증강된 이미지로 이루어진 Training set과 이를 검증하기 위한 Test set의 비율을 hold-out 교차검증에서 주로 사용되는 7:3으로 유지하기 위해 Training set은 기존 이미지 36개와 증강된 이미지 108개의 합인 총 144개로 설정하고 Test set은 60개로 설정한다. 증강된 이미지 (M, S, R)는 데이터증강 모델의 조합 개수(1개, 2개, 3개)에 따라 기존 이미지(B)를 임의대로 선택 (36개, 18개, 12개)하여 데이터증강 모델별 3장씩 증강되었다. 데이터증강 유무에 따른 객체탐지 성능을 연구하기 위해 Experiment #1을 실시하고 데이터증강 방법에 따른 객체탐지 성능을 연구하기 위해 Experiment #2~#8을 실시한다. 이 때, 데이터 수의 증가로 인한 객체탐지 성능의 영향을 최소화하기 위해 전체 데이터의 수는 204개로 통제하고 증강방식에 따른 데이터 수만 조작한다.

Table 4 Experiment

Experiment		#1 (B)	#2 (M)	#3 (S)	#4 (R)	#5 (MS)	#6 (MR)	#7 (SR)	#8 (MSR)
Training set	Basis (B)	36	36	36	36	36	36	36	36
	Mosaic Augmentation (M)	0	108	0	0	54	54	0	36
	SinGAN (S)	0	0	108	0	54	0	54	36
	RandAugment (R)	0	0	0	108	0	54	54	36
Test set		60	60	60	60	60	60	60	60
Total		96	204	204	204	204	204	204	204

4.4 평가 지표

객체탐지 모델 YOLOv5s의 성능을 평가하기 위해서 AP(Average Precision) 평가지표를 사용하고 증강모델별 활용도에 참고가 가능하도록 모델별 컴퓨팅 시간을 제시한다. 본 연구에서 평가지표로 사용되는 AP는 IoU(Intersection over Union)가 0.5 보다 큰 값이 나오는 예측을 TP(True Positive) 값으로 사용한다. 해당 척도에 대한 세부적인 내용은 다음과 같다.

4.4.1 IoU

IoU는 Fig. 10과 같이 실제 바운딩 박스인 Ground Truth와 객체탐지 모델이 예측한 바운딩 박스인 Prediction이 얼마나 정확히 겹치는지 계산한 값으로 수식으로 나타내면 식 (1)과 같다.

$$IoU = \frac{area(B_{gt} \cap B_p)}{area(B_{gt} \cup B_p)} = \frac{(Intersection)}{(Union)} \quad (1)$$

B_{gt} : 실제 Bounding Box

B_p : 예측 Bounding Box




Fig. 10 Example of IoU

4.4.2 Precision과 Recall

Precision과 Recall을 구하기 위해서는 Table 5와 같은 객체탐지 모델의 예측 오류를 보여주는 혼동행렬(Confusion Matrix)에 대한 이해가 필요하다. TP는 객체탐지 모델에 의해 검출되어야 하는 객체가 검출된 결과, FN은 검출되어야 하는 객체가 검출되지 않은 결과, FP는 검출되지 않아야 하는 객체가 검출된 결과, TN은 검출되지 않아야 하는 객체가 검출되지 않은 결과를 뜻한다.

Table 5 Confusion matrix

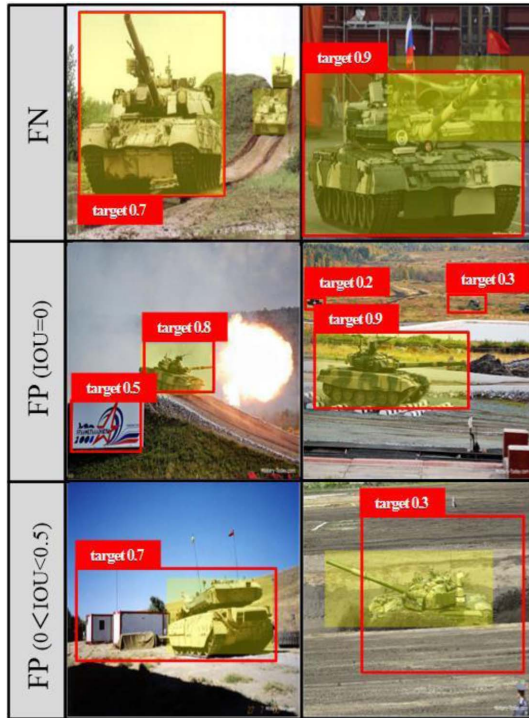
Ground truth	Predict result	
	Positive	Negative
Positive	TP (True Positive)	FN (False Negative)
Negative	FP (False Positive)	TN (True Negative)

Fig. 11은 데이터의 학습 과정에서 나타난 YOLOv5s의 적성 전차 탐지간 발생한 오류의 예시이다. 탐지되어야 할 전차가 탐지되지 않은 FN 상황, 전차가 아닌 광고판이 탐지되거나 전차 주변 컨테이너박스를 포함하여 탐지하는 FP의 상황이 발생하였다.

Precision은 정확도를 의미하며 식 (2)와 같이 모델이 정답이라고 검출한 결과들 중에서 실제 정답을 검출한 비율을 뜻한다. Recall은 재현율을 의미하며 식 (3)과 같이 실제 정답 중에 모델이 정답이라고 검출한 비율을 뜻한다.

$$\text{Precision} = \frac{TP}{TP+FP} = \frac{TP}{\text{All Detections}} \quad (2)$$

$$\text{Recall} = \frac{TP}{TP+FN} = \frac{TP}{\text{All Ground truths}} \quad (3)$$



: Ground Truth : Prediction

Fig. 11 Example of errors

4.4.3 PR curve와 AP

PR curve는 Fig. 11의 Prediction 바운딩 박스 좌측 상단 숫자이자 객체탐지 모델이 검출한 결과에 대한 확신 정도를 나타내는 Confidence level을 기준으로 내림차순으로 정리하여 Precision과 Recall 값을 표시한 결과이다. Confidence level이 높을수록 객체탐지 모델이 객체를 탐지한 결과를 참값으로 확신할 수 있다. 본 실험에서는 YOLOv5s 모델의 Confidence threshold를 0.01로 설정하여 탐지한 모든 결과들에 대한 Precision과 Recall 값을 반영하였다.

Precision과 Recall 값만으로는 객체탐지 알고리즘의 성능을 나타내기 어렵다. Precision 값이 높을 경우 Recall 값은 낮은 경향이 있고, Precision 값이 낮을 경우 Recall 값이 높은 경향이 있다. 즉, 많은 객체를 탐지할수록 정확하게 탐지할 확률이 적어진다. 이러한 문제 속에서 객체탐지 모델의 성능을 전반적으로 하나의 숫자로 표현하기 위해 PR curve (Precision-Recall curve)의 아래면적 넓이에 해당하는 AP를 객체탐지 모델의 성능 평가지표로 주로 사용한다. Fig. 12는 실험의 최종 학습 결과로 도출된 PR curve와 아래면적의 넓이에 해당하는 AP이다.

4.5 실험 결과

본 연구에서 사용한 데이터증강 모델별 이미지 1개에 대한 데이터증강 컴퓨팅 시간은 Fig. 13과 같다. 시간 단위(ms)를 고려해보면 SinGAN 모델

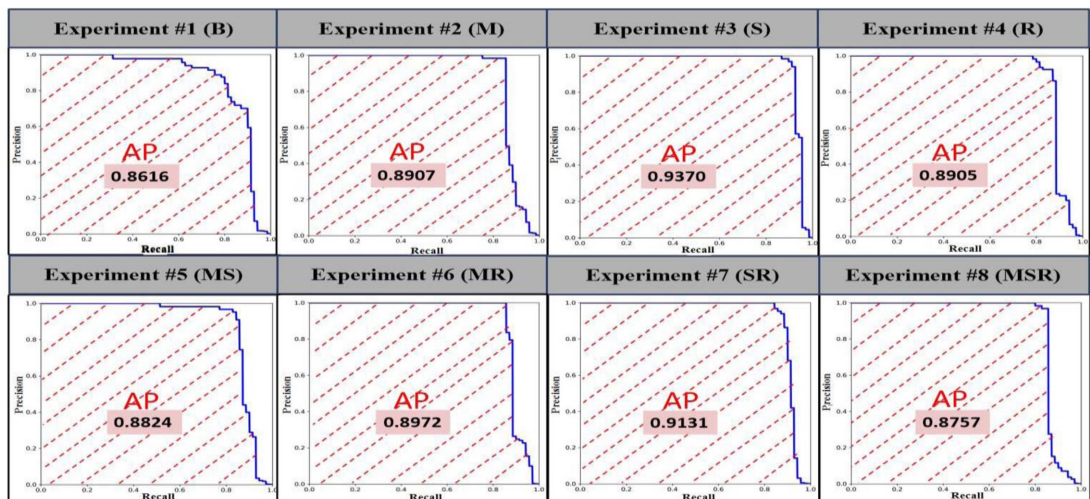


Fig. 12 PR curve of Experiment #1~#8


Table 6 Average of Training / test loss in each batch size and epoch

Epoch \ Batch size	20	40	60	80	100	120	140	160
4	0.09620 / 0.09249	0.07813 / 0.08004	0.07447 / 0.07904	0.06809 / 0.07113	0.05511 / 0.06701	0.05724 / 0.06849	0.05594 / 0.06680	0.05372 / 0.06611
8	0.08113 / 0.08221	0.06007 / 0.06599	0.05103 / 0.05509	0.04105 / 0.04401	0.04008 / 0.04377	0.03970 / 0.04216	0.03893 / 0.04091	0.03901 / 0.04002
16	0.05135 / 0.04918	0.03581 / 0.04271	0.03060 / 0.03526	0.02702 / 0.03882	0.02711 / 0.03855	0.02681 / 0.03898	0.02788 / 0.03990	0.02678 / 0.03871
32	0.07556 / 0.07440	0.05850 / 0.05915	0.04704 / 0.05010	0.04288 / 0.04656	0.04108 / 0.04334	0.03811 / 0.04036	0.03707 / 0.04098	0.03801 / 0.04102

* Number1 / Number2 : Training loss / Test loss

은 다른 두가지 모델에 비해 데이터증강에 소요되는 시간이 매우 높다.

YOLOv5s 객체탐지 모델을 활용하여 Table 2

**Fig. 13** Data augmentation average time for processing one image on CPU/GPU

Military Tank Dataset 학습 과정간 하이퍼파라미터 최적화는 그리드 서치라는 직관적인 방법을 사용하였고 결과는 Table 6과 같다. Batch size는 Training loss와 Test loss가 최소가 되는 16으로 설정하였고 epoch는 80 이후 loss 값의 유의미한 변화가 없어 80으로 설정하였다.

Fig. 14는 YOLOv5s 객체탐지 모델을 활용하여 실험 데이터셋의 학습 과정에서 Precision, Recall, AP값을 보여준다. 그래프와 같이 데이터증강 모델을 적용하였을 때 결과값들은 기존 데이터셋인 B와 다르게 epoch가 50 이후로는 결과값에 큰 변화가 없을 정도로 빠른 시간에 최적값이 도출되었다.

Table 7은 각 실험별 모든 Confidence level에서 Precision, Recall의 평균값, 객체탐지 모델의 성능 평가지표인 AP 값을 제시하였다. 기존 데이터셋

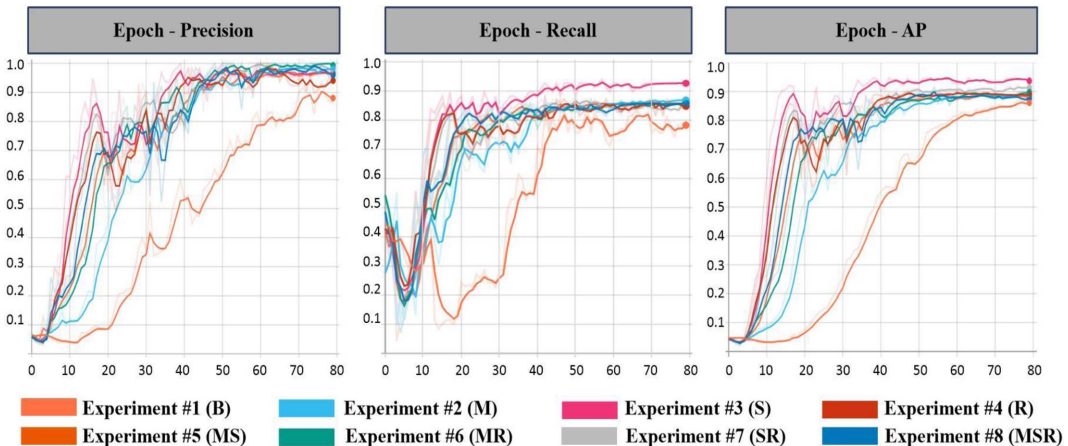
**Fig. 14** Epoch – Precision, Recall, AP of YOLOv5s model

Table 7 Precision, Recall and AP in each experiment

Experiment	#1 (B)	#2 (M)	#3 (S)	#4 (R)	#5 (MS)	#6 (MR)	#7 (SR)	#8 (MSR)
Precision	0.8804	0.9815	0.9655	0.9407	0.9673	0.9930	0.9694	0.9603
Recall	0.7828	0.8689	0.9264	0.8473	0.8569	0.8628	0.8634	0.8564
AP	0.8616	0.8907	0.9370	0.8905	0.8824	0.8972	0.9131	0.8757

인 B에서 증강된 데이터가 추가된 데이터셋들은 B 보다 높은 객체탐지 성능을 보였다. AP는 작게는 0.0141 차이부터 크게는 0.0754 차이를 보였다. 이러한 차이는 무기체계 활용에 있어 유의미한 수치로 판단된다.

가장 높은 객체탐지 성능을 보인 데이터셋은 SinGAN을 활용한 증강 데이터만 포함된 S의 AP가 0.9370으로 다른 실험들에 비해 높은 성능을 보여주었다. S는 36개의 기존 데이터를 모두 SinGAN 모델로 증강을 시켜 다른 실험들에 비해 데이터증강 컴퓨팅 시간이 가장 높게 소요되었다.

Mosaic Augmentation과 RandAugment를 단독으로 활용한 증강 데이터에서의 객체탐지 성능은 M의 결과인 0.8907과 R의 결과인 0.8905와 같이 큰 차이를 보이지는 않았다. 위의 모델들을 SinGAN을 통한 증강 데이터와 조합해서 데이터셋을 구성하였을 경우 MS의 결과인 0.8824보다 SR의 결과가 0.9131로 0.0307 높은 성능을 보였다. MR은 MS와 SR의 중간 성능인 0.8972의 성능을 보였다. 모든 데이터증강 모델을 통해 데이터를 증강한 MSR의 AP의 경우 0.8757로 다른 조합 모델들에 비해 객체탐지 성능 향상이 적었다.

5. 결 론

본 연구는 군사 데이터의 특성상 데이터의 수가 적은 적성 전차에 대한 객체탐지 성능을 향상시키기 위한 데이터증강 모델들을 제시하고 데이터증강 모델들의 조합을 통한 객체탐지 성능을 실험 및 평가하였다. 실험을 요약하면 데이터증강을 통해 객체탐지 성능을 향상시키는 것이 가능하고 그 중에서도 특히, GAN 모델 중 하나인 SinGAN을 활용한 데이터증강 모델이 객체탐지 성능 향상에 가장 우수한 결과를 보여주었다. 하지만, 데이터

증강 모델별 데이터를 증강하는데 소요되는 시간을 고려하면 시간과 성능에 대한 효율성 분석이 추가적으로 필요하다.

본 연구에서는 기존 단일 데이터증강법에 따른 객체탐지 성능을 평가한 연구^[7,8,11,14]와 동일하게 제시된 데이터증강 모델들이 객체탐지 성능을 향상시킨다는 것을 보였다. 이외에도 데이터증강 모델들의 조합 방식이 객체탐지 성능에 어떠한 영향을 미치는지에 대한 결과와 모든 데이터증강 모델들을 조합한 결과가 반드시 좋을 수는 없다는 것을 보였다는 것에 본 연구에 의의가 있다.

본 연구를 통해 적성 데이터의 특성상 부족할 수 밖에 없는 상황에서 딥러닝 기반의 객체탐지 기술을 활용할 때, 보다 향상된 기술의 성과를 달성하기 위해서는 데이터증강 모델에 대한 연구가 필요하다는 것을 알 수 있었다. 차후 연구에서는 이러한 연구 결과를 바탕으로 보다 확장된 데이터의 범위와 데이터증강 모델과 같은 다양한 변수들에 따른 객체탐지 성능에 대한 연구가 필요할 것이다.

본 연구에 대한 제한사항으로는 적성 전차 데이터를 묘사하기 위해 이와 유사한 전차 이미지를 활용하여 데이터셋을 구성한 점과 보다 다양한 데이터증강 모델을 적용하지 않았다는 점이다. 차후 군사 감시정찰 자산 및 첩보를 통해 적성 전차에 대한 빅데이터의 구성과 이에 적합한 데이터증강 모델에 대해 연구할 경우 보다 높은 객체탐지 성능 향상이 가능하다. 추가적으로 본 연구의 객체탐지 모델이 탐지하는 객체의 클래스가 ‘전차’라는 1개의 클래스만 탐지하는 실험을 진행하였기 때문에 다수의 객체 클래스가 존재하는 실제 상황에서 발생하는 객체탐지 성능을 반영하기에는 제한사항이 존재한다. 차후에는 다수의 객체 클래스에 대한 데이터증강을 활용한 객체탐지 연구가 요구된다.

References

1. Oh, S.H., Lee, J.R., Choi, B.S., Lim, Y.H., Yoon, J.H., Jin, H., Kim, S.E., Kim, D.B., Kim, G.E., Yang, H.T. and Lee, J.Y., 2020, Strategies for Improving STI Policy Towards a Leading Country in the Application of AI Technology, *Policy Research*, pp.1-405.
2. Yoon, J.H., 2021, Issues and Prospects of AI Utilization in the Defense Field, *STEPI Insight*, pp.36-37.
3. Zhengxia, Z., Zhenwei, S., Yuhong, G. and Jieping, Y., 2019, Object Detection in 20 Years : A Survey, *arXiv preprint arXiv:1905.05055*.
4. Cho, S.Y., 2020, *How to Improve the Accuracy of Deep Learning Networks Through Data Enhancement*, Ph.D. Thesis, Graduate School of Kwangwoon University.
5. Shorten, C. and Khoshgoftaar, T.M., 2019, A Survey on Image Data Augmentation for Deep Learning, *Journal of Big Data*, 6(1), pp.1-48.
6. Bochkovskiy, A., Wang, C.Y. and Liao, H.Y.M., 2020, Yolov4: Optimal Speed and Accuracy of Object Detection, *arXiv preprint arXiv:2004.10934*.
7. Wei, Z., Duan, C., Song, X., Tian, Y. and Wang, H., 2020, AMRNet: Chips Augmentation in Aerial Images Object Detection, *arXiv preprint arXiv:2009.07168*.
8. Hao, W. and Zhili, S., 2020, Improved Mosaic: Algorithms for more Complex Images, In *Journal of Physics: Conference Series*, IOP Publishing, 1684(1), p.012094.
9. Shaham, T.R., Dekel, T. and Michaeli, T., 2019, Singan: Learning a Generative Model from a Single Natural Image, *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pp.4570-4580.
10. Kwon, J.W., Yoon, G.J., Kim, S.J., Jung, Y.C. and Kwon, S.C., 2020, Study of Pathology Data Augmentation Technique Using SinGAN, *Academic Conference of the Korean Electronic Engineering Association*, pp.995-998.
11. Chen, G., Bai, X., Wang, G., Wang, L., Luo, X., Ji, M. and Zhang, Y., 2021, Subsurface Voids Detection from Limited Ground Penetrating Radar Data Using Generative Adversarial Network and YOLOV5, *2021 IEEE International Geoscience and Remote Sensing Symposium IGARSS*, pp.8600-8603.
12. Cubuk, E.D., Zoph, B., Shlens, J. and Le, Q.V., 2020, Randaugment: Practical Automated Data Augmentation with a Reduced Search Space, *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops*, pp.702-703.
13. Yao, P., Shen, S., Xu, M., Liu, P., Zhang, F., Xing, J. and Xu, R.X., 2021, Single Model Deep Learning on Imbalanced Small Datasets for Skin Lesion Classification, *IEEE Transactions on Medical Imaging*.
14. Lee, K.W., Kim, Y.M. and Hong, A.Y., 2021, Implementation of RandAugment for Crop Detection in Harvesting Robots, *A Dissertation Collection of Domestic Academic Conferences of the Control Robot System Association*, pp.657-658.
15. Lim, S.G. and Kang, D.S., 2021, Identification and Evaluation of Tank Nationality using YOLO Algorithm, *KIISE Transactions on Computing Practices*, 27(12), pp.555-562.
16. Kim, G.G., No, C.M., Lee, S.B., Lee, S.S. and Lee, J.C., 2021 A Study on the Data Pre-processing Method for Recognizing Small Objects in the Sea, *Korean Journal of Computational Design and Engineering*, 26(4), pp.366-375.
17. Kim, J., Park, J. and Moon, H., 2020, A Study on the Multinational Warship Detection and Classification Model Using Deep Learning, *Korean Society for Defense Management Analysis*, 46(2), pp.73-83.
18. Jang, J. and Lee, S., 2020, A Coupled CNN Algorithm for the Reduction of False Positive Rate in Detecting Aircraft within Satellite Imagery, *Journal of the Military Operations Research Society of Korea*, 76(3), pp.61-90.
19. YOLOV5-Master (<https://github.com/ultralytics/yolov5.git>)
20. Zhu, L., Geng, X., Li, Z. and Liu, C., 2021, Improving YOLOv5 with Attention Mechanism for Detecting Boulders from Planetary Images, *Remote Sensing*, 13(18), p.3776.
21. Choi, H.H., 2015, Changes in the North Korean Military Weapon System, *Defense and Technology*, (431), pp.22-29.
22. Military Tank Dataset (<https://www.kaggle.com/antoreepjana/military-tanks-dataset-images/tasks>).



황 교 성

2010년~2014년 육군사관학교 무기
시스템공학 학사
2021년~현재 국방대학교 국방과학
학과 석사과정
관심분야: 인공지능, 무기체계 획득
관리, 국방 M&S
이메일: rytjd0750@gmail.com



마 정 목

1998년~2002년 육군사관학교 운영
분석 학사
2006년~2008년 미국 펜실베이니아주
립대(PSU) 산업공학 석사
2011년~2015년 미국 일리노이대
(UIUC) 산업공학 박사
2015년~현재 국방대학교 국방과학
학과 부교수
관심분야: 국방 모델링 및 데이터분
석학, 무기체계 획득관리
이메일: jxm1023@gmail.com